


Equipo 4



Detección de Plagio en Código Fuente

Angel Francisco Garcia - A01704203
Emilio Leví Díaz Abarde - A01620887



Problemática y Justificación

El plagio de código no solo representa un problema académico o ético, sino también un riesgo para la seguridad y la confiabilidad de los sistemas informáticos.

La reutilización de código sin una revisión adecuada puede introducir errores, vulnerabilidades o incluso componentes maliciosos en aplicaciones y proyectos.


Esto puede afectar la experiencia de los usuarios y, en sistemas críticos, tener consecuencias graves.

Por ejemplo, en software utilizado en la aviación, dispositivos médicos o sistemas de administración de insulina, una falla derivada de código no verificado podría comprometer la seguridad de las personas e incluso poner vidas en riesgo.





Objetivos



General

Crear exitosamente un modelo de Machine Learning que clasifique si hay plagio entre dos archivos de código

Específicos

- Llegar a un valor de accuracy encima del 90%
- Tener un valor de recall por encima del 90% considerando la naturaleza del problema

Descripción del Modelo

Tipo de Modelo



Es un modelo de red neuronal clasificador, en donde se clasifica un par de códigos en “plagio” o “no plagio” en base a sus métricas


Justificacion

Al utilizar múltiples dimensiones para clasificar código (0 o 1), una red neuronal es altamente compatible con la solución del problema.

Descripcion del Modelo



2 layers, dropout de 30%, activación ReLu y Sigmoid en la capa final (al ser un modelo de clasificación binaria)






Resultados Obtenidos

Recall: 1.0 Accuracy: 0.99



Estado del Arte



Utilización de Embedding Unixcoder

En los artículos del estado del arte se encontró que utilizar el tokenizador y modelo de embedding Unixcoder fue el más efectivo entre varios otros

SMOTE-ENN


La utilización de SMOTE-ENN para balancear clases dentro de conjunto de datos que presentan un claro imbalance

Conjunto de datos SOCO FIRE 2014


El conjunto de datos más comúnmente usados dentro de los estudios del estado del arte es SOCO

Medidas de similitud

En el estado del arte se emplean 6 diferentes formas de medir la similitud de un código




Mejoras Potenciales



Otros modelos del estado del arte utilizan otros tipos de modelos como Random Forest. Se pueden investigar más opciones de modelos para verificar si una red neuronal es el mejor tipo o si existen mejores.

Además, se pueden implementar más datasets con más lenguajes de programación y un mayor balance de clases para reducir la necesidad de utilizar datos aumentados artificialmente.



Referencias



Pham, H. V., Chu, T., Le, T. M., Tran, H. M., Tran, H. T. K., Yen, K. N., & Dao, S. V. T. (2025). Comprehensive evaluation of bankruptcy prediction in Taiwanese firms using multiple machine learning models. *International Journal of Technology*, 16(1), 289–309. <https://doi.org/10.14716/ijtech.v16i1.7227>

F. Ebrahim and M. Joy, Semantic Similarity Search for Source Code Plagiarism Detection: An Exploratory Study. 2024, pp. 360–366. doi: 10.1145/3649217.3653622.

F. Ebrahim and M. Joy, Source Code Plagiarism Detection with Pre-Trained Model Embeddings and Automated Machine Learning. 2023, pp. 301–309. doi: 10.26615/978-954-452-092-2_034.

H. Cheers, Y. Lin, and W. Yan, “Identifying Plagiarised Programming Assignments with Detection Tool Consensus,” *Informatics in Education*, Apr. 2022, doi: 10.15388/infedu.2023.05.

S. Feng, W. Suo, Y. Wu, D. Zou, Y. Liu, and H. Jin, Machine Learning is All You Need: A Simple Token-based Approach for Effective Code Clone Detection. 2024, pp. 1–13. doi: 10.1145/3597503.3639114.

H. Cheers and Y. Lin, “Identifying plagiarised programming assignments based on source code similarity scores,” *Computer Science Education*, vol. 33, no. 4, pp. 621–645, Apr. 2022, doi: 10.1080/08993408.2022.2060633.

Thank you!

